

# Identifikasi Fraktur pada Tulang Manusia Hasil X-Ray Menggunakan Klasifikasi SVM

Reva Rayhansyahroni N.<sup>1\*</sup>, Mikhael Irwanto<sup>2</sup>, Garret Junior Tanzil<sup>3</sup>, Timotius Setiawan<sup>4</sup>

<sup>1,2,3,4</sup>Program Studi Teknik Informatika, Universitas Surabaya, Surabaya, Jawa Timur

Email: <sup>1\*</sup>s160421103@ubaya.ac.id, <sup>2</sup>160421137@student.ubaya.ac.id, <sup>3</sup>160421097@student.ubaya.ac.id,  
<sup>4</sup>160421132@student.ubaya.ac.id

## Abstrak

Identifikasi fraktur pada tulang manusia merupakan aspek penting dalam diagnosis medis, yang memerlukan analisis yang tepat terhadap pola visual dalam citra medis. Penelitian ini menggunakan dataset Fracture Multi-Region X-ray Data dari Kaggle, yang terdiri dari dua kelas: fraktur dan non-fraktur. Untuk mengklasifikasikan citra ini, metode Support Vector Machine (SVM) diterapkan. Tujuan penelitian adalah untuk mengevaluasi model klasifikasi berbasis SVM untuk membedakan citra X-ray tulang yang patah dan tidak patah dengan akurasi yang tinggi. Preprocessing dilakukan pada citra X-ray, termasuk konversi ke citra grayscale dan pengubahan ukuran menjadi 150 x 150 piksel. Setelah itu, citra diratakan menjadi vektor satu dimensi. Model SVM kemudian dilatih menggunakan data pelatihan dan diuji menggunakan data pengujian. Evaluasi akurasi model menunjukkan bahwa model SVM mencapai akurasi sebesar 100% dalam membedakan citra X-ray tulang yang mengalami fraktur dan tidak patah. Hasil ini menunjukkan bahwa SVM dapat menjadi alat bantu diagnostik yang efisien, memberikan diagnosis yang cepat dan akurat dalam identifikasi fraktur pada citra X-ray.

**Kata Kunci:** Identifikasi Fraktur, Citra X-ray, Support Vector Machine, Diagnosa Medis, Klasifikasi.

## *Identification of fractures in human bone x-ray images also uses SVM classification*

### Abstract

Identification of fractures in human bones is an important aspect of medical diagnosis, requiring accurate analysis of visual patterns in medical images. This research utilizes the Fracture Multi-Region X-ray Data dataset from Kaggle, consisting of two classes: fractures and non-fractures. To classify these images, the Support Vector Machine (SVM) method is applied. The research aim is to evaluate the SVM-based classification model to distinguish between fractured and non-fractured bone X-ray images with high accuracy. Preprocessing is performed on the X-ray images, including conversion to grayscale and resizing to 150 x 150 pixels. Subsequently, the images are flattened into one-dimensional vectors. The SVM model is then trained using training data and tested using testing data. Evaluation of the model's accuracy shows that the SVM model achieves an accuracy of 100% in distinguishing between bone X-ray images with fractures and without fractures. These results indicate that SVM can be an efficient diagnostic tool, providing fast and accurate diagnosis in identifying fractures in X-ray images.

**Keywords:** Fracture Identification, X-ray Images, Support Vector Machine, Medical Diagnosis, Classification.

---

## I. PENDAHULUAN

Secara global, terdapat 178 juta kasus patah tulang (*bone fracture*) yang baru hanya dari 1990 hingga 2019 saja. Ini menandakan peningkatan sebesar 33.4% sejak 1990, yang

tidak termasuk kasus-kasus yang terjadi pada periode 1990 hingga 2019 yang bersifat kronis [1].

Walaupun tingkat kematian yang disebabkan oleh patah tulang kurang dari 1% pada pasien dibawah umur 65, dan

7% pada pasien pada pasien diatas umur 65 [2] - Konsekuensi jangka panjang dari patah tulang juga bisa berdampak negatif pada kehidupan sosial, fisik, finansial, dan psikologis pasien yang telah mengalami patah tulang [3].

Prosedur pemeriksaan menggunakan *X-ray* bisa disebut juga dengan nama pemeriksaan rontgen dan prosedur ini dapat dilakukan dengan waktu yang relatif cepat. Namun, waktu yang diperlukan dokter untuk mengambil kesimpulan berdasarkan foto rontgen tersebut terkadang bisa dibilang dapat memakan waktu yang lebih lama daripada proses rontgen. Apalagi jika luka yang dialami oleh korban sangat parah dan membutuhkan diagnosis yang cepat dan akurat.

Oleh karena itu penulis bertujuan untuk mempercepat proses pendeteksian fraktur pada citra *X-ray* tulang manusia dengan harapan bahwa proses pendeteksian ini akan dilakukan secara otomatis tanpa perlu pengecekan secara manual yang dapat membuang waktu dan sistem akan memberikan hasil yang akurat dan terjamin.

Harapan dari pengembangan sistem ini adalah untuk menyediakan alternatif yang dapat diandalkan, sehingga sumber daya manusia dapat dialokasikan kegiatan lain dalam situasi darurat maupun normal.

Penelitian sebelumnya menunjukkan berbagai pendekatan dalam pengembangan sistem otomatis untuk deteksi fraktur pada citra X-ray. Misalnya, Rajpurkar et al. (2017) mengembangkan model berbasis deep learning yang dikenal sebagai CheXNet, yang berhasil mencapai tingkat akurasi yang tinggi dalam mendeteksi pneumonia dari citra X-ray dada, dan metodenya dapat diadaptasi untuk deteksi fraktur tulang[7]. Sebuah penelitian oleh Olczak et al. (2017) mengevaluasi kinerja algoritma convolutional neural network (CNN) dalam mendeteksi fraktur pada citra X-ray dan menemukan bahwa performa algoritma tersebut dapat menyaingi radiolog berpengalaman [8]. Selain itu, Chung et al. (2020) mengembangkan sistem deteksi otomatis menggunakan metode ensemble deep learning yang menggabungkan beberapa model CNN untuk meningkatkan akurasi deteksi fraktur, yang terbukti efektif dalam mengidentifikasi berbagai jenis fraktur [9]. Penelitian-penelitian ini memberikan landasan yang kuat untuk pengembangan lebih lanjut dalam otomatisasi deteksi fraktur pada citra X-ray, dengan harapan meningkatkan efisiensi dan akurasi diagnosis.

## II. TINJAUAN PUSTAKA

### A. Identifikasi Fraktur

Identifikasi fraktur adalah proses dalam bidang kedokteran dimana dilakukan analisis terhadap citra *X-ray*, *CT-scan* maupun pemeriksaan secara fisik, untuk mendeteksi adanya retakan atau patahan pada tulang manusia [4]. Proses ini penting dalam diagnosis medis karena memungkinkan dokter atau radiolog untuk mengidentifikasi patah tulang dan merencanakan pengobatan yang tepat .

### B. Support Vector Machine (SVM)

*Support Vector Machine (SVM)* merupakan salah satu algoritma klasifikasi yang sering digunakan untuk pemisah data linear dan non-linear. SVM mencoba untuk menemukan *hyperplane* terbaik yang membagi ruang fitur ke dalam dua kelas dengan margin yang maksimal. Dalam konteks klasifikasi, SVM mencari *hyperplane* yang memaksimalkan jarak antara dua kelas. Data yang berada di dekat *hyperplane* ini disebut sebagai *support vectors*, yang merupakan titik-titik penting dalam menentukan posisi *hyperplane*.

### C. Citra X-Ray

Citra *X-Ray* adalah gambar yang dihasilkan menggunakan sinar-X, jenis radiasi elektromagnetik berpanjang gelombang sangat pendek yang dapat menembus berbagai bahan, termasuk jaringan tubuh manusia. Proses pencitraan melibatkan pemancaran sinar-X melalui objek yang diperiksa, dan menangkap sinar yang diteruskan atau diblok oleh objek tersebut menggunakan detektor khusus atau film fotografi. Citra ini digunakan untuk menganalisis struktur internal objek, seperti tulang, organ, dan jaringan lainnya.

### D. Diagnosa Medis

Diagnosa medis merupakan sebuah proses identifikasi pada suatu gejala penyakit. Pengobatan dan pemeriksaan yang dilakukan dapat diperoleh melalui proses diagnosa medis [6]. Proses diagnosa medis yang dilakukan berupa pengumpulan riwayat medis, pemeriksaan fisik, dan tes diagnostik. Tujuan dari proses diagnosa medis ini adalah mengidentifikasi suatu penyakit secara akurat sehingga proses pengobatan dan perawatan dapat dilakukan secara efektif.

## III. PERNYATAAN MASALAH

Permasalahan yang ingin dibahas dalam artikel ini adalah cara untuk mengembangkan dan mengimplementasikan sistem klasifikasi otomatis berbasis SVM untuk mengidentifikasi fraktur pada tulang manusia dari citra *X-ray* dengan tingkat akurasi yang tinggi menggunakan metode *support vector machine*. Berdasarkan dari dataset yang diambil dari kaggle, akan dilakukan analisa untuk mengetahui keakuratan dan metode evaluasi yang digunakan pada penelitian.

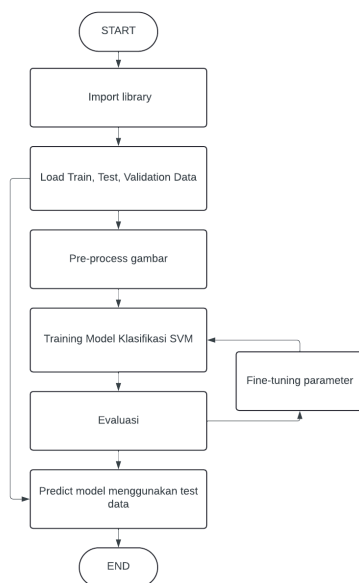
Fokus utama dalam penelitian ini adalah untuk mempelajari seberapa efektif metode klasifikasi SVM dalam identifikasi fraktur pada tulang manusia berdasarkan hasil *X-Ray*. Berdasarkan data citra *X-Ray* yang telah dilatih dan diuji, dilakukan analisis menggunakan metode evaluasi model untuk mengetahui seberapa akurat dan efektif klasifikasi fraktur pada dataset gambar yang digunakan.

Masalah umum dalam klasifikasi fraktur tulang menggunakan hasil *X-ray* dengan metode SVM adalah meningkatkan akurasi dan efektivitas sistem. Masalah ini mencakup variabilitas kualitas gambar *X-ray*, keharusan untuk preprocessing gambar yang optimal, kesulitan dalam

ekstraksi fitur yang relevan, variasi bentuk dan ukuran fraktur, ketidakseimbangan dataset, serta kebutuhan akan validasi yang baik untuk mencegah *overfitting* dan memastikan generalisasi model. Selain itu, pengaturan parameter SVM yang kompleks dan kebutuhan interpretabilitas hasil klasifikasi juga menjadi hambatan signifikan dalam mengembangkan sistem yang handal dan aplikatif di dunia klinis.

#### IV. METODE

Tahap-tahap pada proses klasifikasi ini bisa dilihat pada gambar berikut.



Gambar 1. *Flowchart* Proses Klasifikasi.

##### A. Dataset

Dataset yang digunakan telah diambil dari *kaggle*, sebuah media kumpulan dataset yang terpercaya [5]. Dataset yang digunakan merupakan kumpulan dari dataset-dataset lainnya. Dataset tersebut mengandung 10.580 citra *X-ray* tulang manusia, diantaranya 9.246 citra digunakan untuk *data training*, 828 citra untuk validasi data, dan 506 citra untuk *data testing*. Masing-masing kategori citra dikelompokkan berdasarkan kondisi tulang, yaitu tulang yang patah dan tulang yang tidak patah.

##### B. Library yang digunakan

###### i) Drive

Merupakan sebuah metode yang disediakan oleh *Google Colab* yakni *environment* yang digunakan untuk program klasifikasi ini, agar dapat mengakses dataset yang berada di *Google Drive*.

###### ii) Numpy

Digunakan untuk melakukan proses matematis

seperti menyimpan sebuah *array* ke dalam variabel.

###### iii) Matplotlib

Digunakan untuk menampilkan citra dalam format grafik.

###### iv) cv2

Digunakan untuk membaca, serta memproses citra.

###### v) os

Digunakan untuk menampilkan maupun mengolah direktori pada dataset yang telah disimpan di *Google Drive*.

###### vi) sklearn

Digunakan untuk mengimplementasikan algoritma klasifikasi *SVM* serta mengukur tingkat keakuratan dari hasil klasifikasinya.

#### C. Pre-processing

Persiapan pada data yang penulis lakukan adalah hanya menggunakan metode *resize* pada library *cv2*, diubah menjadi ukuran 150x150 pixel.


Parameter yang dipakai saat *resize* adalah *interpolation*, yang berguna untuk memilih metode apa yang dipakai untuk menentukan nilai pixel pada gambar yang ukurannya diubah. Metode yang terpilih adalah *cv2.INTER\_AREA* yang bekerja dengan cara *resample* menggunakan hubungan pada area pixel.

Setelah mengubah ukuran gambar, langkah selanjutnya adalah menggunakan metode *flatten()* pada gambar agar matrix gambar tersebut berubah menjadi vektor 1 dimensi, hal ini ditujukan pada input di model yang biasanya hanya menerima vektor 1D.


#### D. Model Klasifikasi

*Classifier* yang dipilih oleh penulis adalah *Support vector machines* (SVMs) dari library *scikit-learn*. SVM sendiri adalah sebuah set yang terdiri dari metode-metode *supervised learning* yang digunakan untuk klasifikasi, regresi, dan deteksi *outliers* [10].

Proses klasifikasi SVM dapat diimplementasikan menjadi 2 tahap yaitu *training* dan *testing*. Proses training SVM dapat dilihat pada Gambar 2 dan proses testing SVM dapat dilihat pada Gambar 3.



Gambar 2. Diagram Alur Training SVM



Gambar 3. Diagram Alur Testing SVM

SVC adalah *class* yang ada pada *library* SVM yang digunakan untuk *binary* dan *multi-class classification*. Dalam SVC terdapat beberapa rumus yang telah diimplementasikan. Beberapa rumus tersebut adalah sebagai berikut.

$$f(x) = w^T x + b \quad (1)$$

Keterangan

$x$  = vektor data yang ingin diprediksi

$w$  = vektor bobot (weight)

$b$  = bias/konstanta penentu posisi hyperplane

$f(x) \geq 0$ ,  $x$  diklasifikasikan ke kelas positif

$f(x) \leq 0$ ,  $x$  diklasifikasikan ke kelas negatif

Penulis menggunakan SVC ini dengan parameter *kernel* yang bertujuan untuk memilih sebuah kernel yang dipakai di algoritma. Kernel mengubah data ke sebuah ruang untuk memudahkan pemisahan data menggunakan *hyperplane*. nilai 'linear' adalah kernel yang paling simpel, sehingga *hyperplane* akan berbentuk garis lurus.

#### E. Evaluasi

Evaluasi model klasifikasi digunakan untuk melihat hasil *training* dan hasil prediksi menggunakan model yang sudah dilatih, sehingga dari hasil tersebut bisa digunakan untuk optimasi model.

Evaluasi yang digunakan pada klasifikasi ini adalah *accuracy\_score* dan *classification\_report*. *accuracy\_score* digunakan untuk mendapatkan akurasi dengan cara membandingkan label pada *test* data dan prediksi label, sedangkan *classification\_report* digunakan untuk memperlihatkan pengukuran-pengukuran utama pada hasil klasifikasi.

Untuk menjamin bahwa model yang sudah dikembangkan dapat digeneralisasikan ke sampel yang diluar dari dataset, akan dilakukan uji coba prediksi terhadap citra yang tidak digunakan dalam proses *training* maupun *testing*.

## V. HASIL DAN PEMBAHASAN

#### A. Uji Coba Sistem

Bentuk data pada dataset yang digunakan adalah dalam bentuk gambar. Gambar-gambar tersebut disimpan dalam berbagai macam *extension*, seperti jpeg, jpg, dan png. Untuk pembagian atau distribusi data tersebut sudah dibagi oleh pemilik dataset dengan jumlah sebagai berikut.

Tabel 5.1 Jumlah Distribusi Data Ke Kelas *Training*, *Validation* dan *Test*

Distribusi	Jumlah
Training	9246
Validation	828
Test	506

Proses *Pre-processing* yang penulis lakukan hanyalah *read* gambar dengan *grayscale*, melakukan *resize* gambar ke ukuran 150x150 pixel dengan parameter *interpolation=cv2.INTER\_AREA*, dan melakukan *flatten* gambar sebelum melakukan *training*. Alasan penulis menggunakan parameter interpolasi tersebut adalah *INTER\_AREA* cocok saat digunakan untuk mengecilkan sebuah gambar.

Dalam uji coba menggunakan citra *X-ray* dari sumber lain yang tidak digunakan dalam proses *testing* maupun *training*, telah terbukti bahwa model juga dapat digeneralisasikan terhadap citra *X-ray* tulang manusia secara keseluruhan.



Gambar 4. Contoh Uji Coba Prediksi Dengan Citra *X-ray* Dari Sumber Lain [11]

#### i) Akurasi Uji Coba Kernel

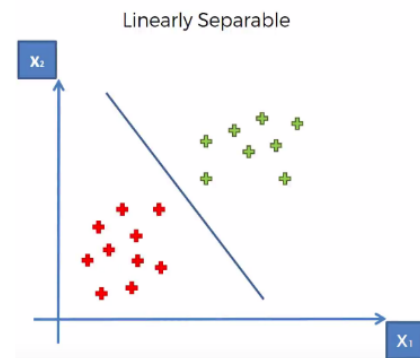
Dalam pengembangan model klasifikasi, fungsi *kernel* yang di telah uji coba akurasi adalah sebagai berikut:

**Tabel 5.1 Jumlah Distribusi Data Ke Kelas *Training*, *Validation* dan *Test***

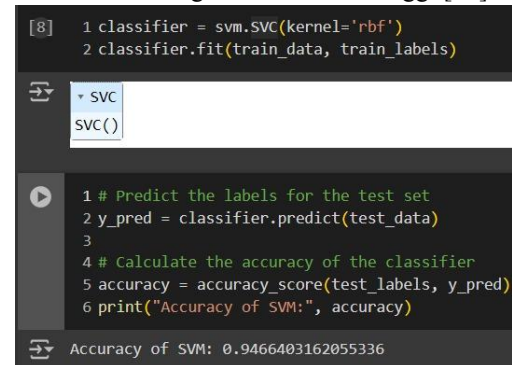
Kernel	Akurasi (%)
RBF	95%
Linear	100%
Poly	98%
Sigmoid	52%

Terlihat bahwa fungsi penggunaan kernel *linear* dalam model klasifikasi biner ini memiliki akurasi yang sempurna yaitu 100%. Dikarenakan fungsi *linear* mampu melakukan klasifikasi terhadap data yang terpisah secara *linear* atau

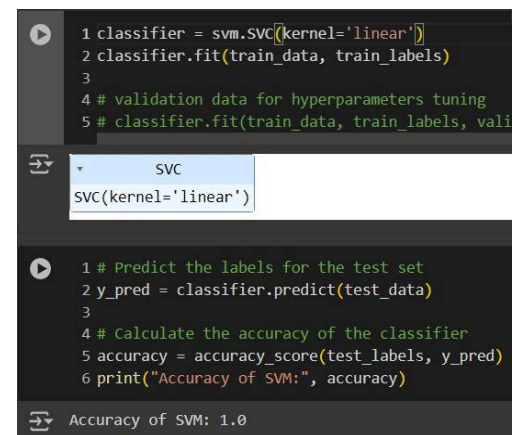
hampir *linear*, dimana margin antara dua kelas tersebut sangat luas [12].



Gambar 5. Contoh Data *Binary Classification* Yang Memiliki Margin Antar Kelas Tinggi [13]



Gambar 6. Hasil Akurasi Kernel '*rbf*'



Gambar 7. Hasil Akurasi Kernel '*linear*'

```

1 classifier = svm.SVC(kernel='poly')
2 classifier.fit(train_data, train_labels)

[11] 1 # Predict the labels for the test set
      2 y_pred = classifier.predict(test_data)
      3
      4 # Calculate the accuracy of the classifier
      5 accuracy = accuracy_score(test_labels, y_pred)
      6 print("Accuracy of SVM:", accuracy)

Accuracy of SVM: 0.9822134387351779

```

Gambar 8. Hasil Akurasi Kernel 'poly'

```

1 classifier = svm.SVC(kernel='sigmoid')
2 classifier.fit(train_data, train_labels)

[13] 1 # Predict the labels for the test set
      2 y_pred = classifier.predict(test_data)
      3
      4 # Calculate the accuracy of the classifier
      5 accuracy = accuracy_score(test_labels, y_pred)
      6 print("Accuracy of SVM:", accuracy)

Accuracy of SVM: 0.5158102766798419

```

Gambar 9. Hasil Akurasi Kernel 'sigmoid'

## B. Evaluasi Sistem

Penulis melakukan evaluasi dengan cara memisahkan data *train* kembali dengan menggunakan metode *train\_test\_split* dengan perbandingan *train:test* adalah 80:20. Kemudian kembali melakukan *training* data pada model yang sudah dibuat dan mendapatkan hasil sebagai berikut.

accuracy: 0.9875742841707186				
classification report:				
	precision	recall	f1-score	support
fractured	0.99	0.98	0.99	921
not fractured	0.98	0.99	0.99	930
accuracy			0.99	1851
macro avg	0.99	0.99	0.99	1851
weighted avg	0.99	0.99	0.99	1851

Gambar 10. Hasil Evaluasi *Stratified Hold Out*

Berdasarkan hasil evaluasi tersebut dapat dilihat bahwa akurasi yang didapatkan sebesar 98% dan dapat dilihat pada laporan klasifikasi.

Class	Metrik	
Fractured	Precision	99% dari <i>fractured</i> yang terprediksi memang benar <i>fractured</i>
	Recall	98% dari yang memang

Not Fractured		benar <i>fractured</i> teridentifikasi dengan benar
	F1-Score	99% menandakan bahwa terdapat keseimbangan yang bagus pada <i>precision</i> dan <i>recall</i>
	Support	Terdapat 921 contoh dari <i>class fractured</i> pada dataset
Not Fractured	Precision	98% dari <i>not fractured</i> yang terprediksi memang benar <i>not fractured</i>
	Recall	99% dari yang memang benar <i>not fractured</i> teridentifikasi dengan benar
	F1-Score	99% menandakan bahwa terdapat keseimbangan yang bagus pada <i>precision</i> dan <i>recall</i>
	Support	Terdapat 930 contoh dari <i>class not fractured</i> pada dataset

## V. KESIMPULAN

Berdasarkan hasil yang didapatkan oleh penulis pada percobaan tersebut, akurasi model klasifikasi yang tinggi menandakan bahwa percobaan ini sukses dalam mengklasifikasikan patah tulang atau tidak patah tulang dari gambar X-ray. Walaupun proses *preprocessing* yang dilakukan relatif sedikit, namun masih bisa mendapatkan akurasi tertinggi. Dengan menggunakan nilai 'linear' pada kernel SVC penulis dapat mencapai akurasi 100%, dan akurasi model secara keseluruhan mencapai 98% setelah melakukan evaluasi. Untuk kelebihan dari proyek adalah dataset yang bagus karena sudah ada augmentasi data dan model ini bisa digunakan sebagai alat diagnosis yang dapat diandalkan, sedangkan kekurangannya adalah dataset yang tidak seragam, seperti gambar dengan latar belakang gelap dan ada juga yang berwarna putih.

Saran untuk pengembangan model ini adalah untuk menyeragamkan semua gambar pada dataset agar bisa lebih mendukung hasil akurasi 100%. Saran lain adalah mempercepat waktu prediksi gambar yang baru, agar proses diagnosis bisa menjadi lebih efisien.

## REFERENSI

- [1] GBD 2019 Fracture Collaborators (2021). Global, regional, and national burden of bone fractures in 204



- countries and territories, 1990-2019: a systematic analysis from the Global Burden of Disease Study 2019. *The lancet. Healthy longevity*, 2(9), e580–e592. [https://doi.org/10.1016/S2666-7568\(21\)00172-0](https://doi.org/10.1016/S2666-7568(21)00172-0)
- [2] Bergh, C., Möller, M., Ekelund, J., & Brisby, H. (2022). Mortality after Sustaining Skeletal Fractures in Relation to Age. *Journal of clinical medicine*, 11(9), 2313. <https://doi.org/10.3390/jcm11092313>
- [3] Singaram, S., & Naidoo, M. (2019). The physical, psychological and social impact of long bone fractures on adults: A review. *African journal of primary health care & family medicine*, 11(1), e1–e9. <https://doi.org/10.4102/phcfm.v11i1.1908>
- [4] Febrina, A. (2024, March 12). Diagnosis fraktur dan dislokasi tulang belakang. Alomedika. <https://www.alomedika.com/penyakit/ortopedi/fraktur-dan-dislokasi-tulang-belakang/diagnosis>
- [5] Rodrigo, M. (2024, April 23). Bone fracture multi-region X-ray data. Kaggle. <https://www.kaggle.com/datasets/bmadushanirodrigo/fracture-multi-region-x-ray-data/data>
- [6] Hussain, S., Mubeen, I., Ullah, N., Shah, S. S. U. D., Khan, B. A., Zahoor, M., ... & Sultan, M. A. (2022). Modern diagnostic imaging technique applications and risk factors in the medical field: a review. *BioMed research international*, 2022(1), 5164970. <https://doi.org/10.1155/2022/5164970>
- [7] Rajpurkar, P., Irvin, J., Zhu, K., Yang, B., Mehta, H., Duan, T., ... & Ng, A. Y. (2017). CheXNet: Radiologist-Level Pneumonia Detection on Chest X-Rays with Deep Learning. arXiv preprint arXiv:1711.05225 <https://arxiv.org/abs/1711.05225>
- [8] Olczak, J., Fahlberg, N., Maki, A., Razavian, A. S., Jilert, A., Stark, A., Sköldenberg, O., & Gordon, M. (2017). Artificial intelligence for analyzing orthopedic trauma radiographs. *Acta Orthopaedica*, 88(6), 581–586. <https://doi.org/10.1080/17453674.2017.1344459>
- [9] Chung, S. W., Han, S. S., Lee, J. W., Oh, K. S., Kim, N. R., Yoon, J. P., Kim, J. Y., Moon, S. H., Kwon, J., Lee, H. J., Noh, Y. M., & Kim, Y. (2018). Automated detection and classification of the proximal humerus fracture by using deep learning algorithm. *Acta orthopaedica*, 89(4), 468–473. <https://doi.org/10.1080/17453674.2018.1453714>
- [10] Scikit-learn developers. (n.d.). Scikit-learn: Support Vector Machines. Retrieved June 17, 2024, from <https://scikit-learn.org/stable/modules/svm.html>
- [11] *Broken+Bones+XRAY images – browse 442 stock photos, vectors, and video*. Adobe Stock. (n.d.). <https://stock.adobe.com/id/search?k=broken%2Bbones%2Bxray>
- [12] Saini, A. (2024, May 22). *Guide on Support Vector Machine (SVM) algorithm*. Analytics Vidhya. <https://www.analyticsvidhya.com/blog/2021/10/support-vector-machinessvm-a-complete-guide-for-beginners/>
- [13] MLMath.io. (2019, February 16). *Math behind svm(kernel trick)*. Medium. <https://ankitnitjsr13.medium.com/math-behind-svm-kernel-trick-5a82aa04ab04>